


El mapa secreto

que encuentra una aguja en un pajar de mil millones

Cómo los grafos hacen posible buscar por significado (sin saber nada de grafos)



Un grafo es... un mapa de amigos




PUNTO = nodo

LÍNEA = arista (relación)


Solo necesitas dos ideas: cosas y conexiones entre ellas. Metro, redes sociales, Google Maps... todo son grafos.

En una base de datos vectorial, cada punto es un texto, foto o canción, y cada línea une a los que se parecen.

El problema: buscar uno a uno no escala




Fuerza bruta: mirar TODOS los puntos



Con grafo: seguir el camino correcto

Con mil millones de puntos, revisar uno a uno tarda demasiado. Aceptamos "casi perfecto" a cambio de responder en milisegundos.

HNSW: autopistas, avenidas y calles



Como llegar a una dirección:

1. Autopista: acercarte mucho, rápido.
2. Avenida: afinar la zona.
3. Calle: encontrar la puerta exacta.

< 20 ms · acierta 95-99%

Es lo más rápido, pero guarda todas esas conexiones en RAM.

El precio de la velocidad: memoria RAM

Guardar el grafo cuesta más que guardar los datos:

$$4 \times D \times N + M \times N \times 8$$

D = tamaño del vector · N = cuántos puntos · M = conexiones por punto. El primer término son los datos; el segundo, las líneas del mapa.

~1 TB

de RAM para 1.000 millones de vectores de 1536 dimensiones

Regla práctica: un índice HNSW ocupa entre 1,5x y 2x el tamaño de los datos crudos.

Buen mapa, pero un mapa gigante necesita una mesa enorme.

Tres trucos para hacer el mapa más pequeño

IVF

Dividir en barrios

Se parte el espacio en zonas (clústeres). Solo buscas en los barrios cercanos. Riesgo: un vecino justo al otro lado de la frontera.

PQ

Comprimir en clave

Cada vector se trocea y se sustituye por códigos de un diccionario. Hasta 32x menos memoria, con pequeña pérdida de precisión.

DiskANN

Mudar el mapa al disco

Solo una fracción vive en RAM; el grafo usa saltos largos para leer poco del SSD. Recorta un 90-95% el coste de memoria.

Y en producción se combinan: IVF-PQ (100M-1.000M de vectores) o HNSW con nodos int8 (4x menos memoria).

Cuando el mapa se rompe: buscar con filtros

"Busca canciones parecidas, pero solo de este cliente." ¿Cuándo filtramos?

Pre-filtrar

Quitamos puntos antes de buscar.

Preciso, pero deja el grafo troceado: caminos rotos, islas sin conexión.

Post-filtrar

Buscamos primero, filtramos después.

Rápido, pero si el filtro es estricto todo se descarta y la respuesta llega vacía.

En la búsqueda

Se comprueba el filtro MIENTRAS se camina por el grafo.

El estándar moderno: usa máscaras de bits y mantiene el recorrido intacto.

¿Cuál elijo? Cinco preguntas, una respuesta



Ojo: no hay índice perfecto. Mejorar precisión, velocidad o memoria siempre cuesta uno de los otros dos.

Para llevarte a casa

- Un grafo es solo puntos y conexiones.
- HNSW navega por capas: autopista, avenida, calle.
- La velocidad se paga con RAM; comprimir o usar disco la abarata.
- Con filtros, el mapa no debe romperse: filtra mientras navegas.
- Si cambias de modelo de embeddings, reconstruye todo el mapa.