



ARQUITECTURA INTERNA DE BASES DE DATOS VECTORIALES


De los algoritmos de indexación al hardware:
Guía de diseño para sistemas a escala de mil millones.



INDEXING ALGORITHMS	IVF	HNSW	DISKANN	
LATENCY	nhose	1.9-5.8	Toa	
THROUGHPUT	N/n	0.6->10n	H/n	
MEMORY USAGE	5.3-1180	8.9	NDB	
SCALE (BILLIONS)	9.9	8	--	

A escala de millones, la fuerza bruta colapsa frente a la aproximación


Búsqueda Exacta (kNN)



Lento, cuello de botella

Precisión 100%, pero la latencia aumenta linealmente.
Práctico solo para $< 100K$ vectores.


Búsqueda Aproximada (ANN)



Rápido, escalable

Intercambia una fracción microscópica de Precisión (Recall) por una velocidad exponencial (búsquedas en milisegundos a escala masiva).

Una Vector Database es un ecosistema de almacenamiento, no solo un índice



1. Capa de Consulta

Procesamiento de similitud, filtrado de metadatos y recuperación del payload original.


2. Capa de Indexación

Mantenimiento de estructuras matemáticas ANN (Grafos, Clústeres) para evitar el escaneo completo.

3. Capa de Ingestión

Persistencia ACID, Write-Ahead Log (WAL), batching y gestión inmutable de memoria.

El triángulo de hierro de la búsqueda vectorial



Los Compromisos de Diseño (Trade-offs)

No existe el índice perfecto. Optimizar un vértice del sistema siempre requiere sacrificar los otros dos.


Caso A: Sistemas RAG / Chatbots

Prioriza Baja Latencia y Alto Recall. Requiere alta Memoria RAM para mantener los índices calientes.

Caso B: Búsqueda Offline Masiva

Prioriza Memoria y Costo. Acepta una mayor Latencia mediante estructuras optimizadas para leer desde Disco (SSD).

HNSW domina la latencia mediante grafos de navegación jerárquica



Mecánica de Búsqueda

La consulta ingresa por la capa superior dispersa (saltos largos) y desciende iterativamente, refinando la precisión hasta alcanzar la capa inferior densa.

Métricas de Diseño


Extraordinaria baja latencia (<20ms) y un altísimo Recall (95-99%).

El Cuello de Botella

Consumo de RAM masivo por el almacenamiento de aristas. Costo de memoria en bytes:

$$4 \times D \times N + M \times N \times 8$$


Inverted File Index (IVF) escala dividiendo el espacio en clústeres



Parámetros Arquitectónicos

nlist (Número de Particiones)

Divide el espacio vectorial completo en un número definido de particiones o celdas geométricas, acotando el área de búsqueda.



nprobe (Clústeres a explorar)


Define cuántas celdas vecinas se explorarán durante la consulta. Un nprobe alto mitiga el 'problema de los bordes' (vectores similares separados por la línea del clúster).



Conclusión Técnica

IVF escala masivamente mejor que HNSW y es altamente paralelizable, asumiendo una ligera penalización en el Recall si la configuración de nprobe es demasiado baja.

Product Quantization (PQ y OPQ) rompe la barrera del consumo de RAM



PQ (Product Quantization)

Logra una **compresión extrema** de hasta 32x.


Permite alojar miles de millones de vectores en memoria RAM utilizando **Asymmetric Distance Computation (ADC)**, asumiendo una leve pérdida de **Recall**.

OPQ (Optimized PQ)


Aplica una **matriz** de rotación previa para balancear la varianza, ideal para Embeddings generados por Transformers.

Incrementa el **Recall** del 82% al 91% manteniendo el mismo nivel de compresión.

Índices compuestos: La fusión estándar en entornos de producción




El caballo de batalla indiscutible para cargas de 100M a 1B de vectores. Logra el equilibrio perfecto entre velocidad de escaneo y bajo consumo de memoria.



Búsqueda topológica ultrarrápida, pero con nodos cuantizados (int8 en lugar de float32). Resulta en una reducción de 4x en la huella de memoria sin perder la estructura del grafo.

Topología de almacenamiento físico: Filas vs. Columnas

Diseño Orientado a Filas (Row-oriented)




Vectores (Densidad Continua)

Los vectores matemáticos requieren una disposición contigua en memoria para el cálculo ultrarrápido de distancias por parte de la CPU/GPU.

Interrumpir esta continuidad destruye el rendimiento.

Diseño Orientado a Columnas (Column-oriented)




Metadatos (Salto Eficiente)

Los metadatos deben aislarse en formato columnar para evitar saturar el ancho de banda I/O. Permite a la base de datos evaluar filtros (ej. 'tenant_id') saltando bloques masivos sin cargar payloads pesados en memoria.

El dilema arquitectónico del filtrado de metadatos


Vía 1: Pre-filtrado

Preciso, pero destruye la topología del índice ANN.
Puede generar grafos huérfanos e inutilizar la búsqueda si el filtro es altamente restrictivo.



Vía 2: Post-filtrado

Extremadamente rápido, pero aniquila el Recall.
Si el filtro es estricto, la búsqueda inicial devuelve resultados que luego son eliminados, retornando respuestas vacías.




Vía 3: Single-Stage (In-Search)

El estándar de oro moderno (Single-Stage).
Evalúa máscaras de bits (bitsets) de metadatos iterativamente bitset evaluado
bitsets) de metadatos de forma iterativa y simultánea mientras recorre la estructura geométrica del grafo.



Query

Rompiendo el límite del Petabyte con DiskANN y Vamana



El Límite Económico de HNSW

Alojar 1,000 millones de vectores a 1536 dimensiones requiere ~1TB de RAM. Escalar esto a nivel empresarial es económicamente inviable en memoria pura.

Algoritmo Vamana (DiskANN)

Optimiza el grafo manteniendo solo una fracción mínima en RAM. Diseña matemáticamente saltos largos (long-range edges) para minimizar las costosas lecturas aleatorias en discos SSD.

Impacto en Producción


Logra una reducción del 90-95% en los costos de infraestructura de memoria RAM, asumiendo una penalización en latencia casi imperceptible. El futuro masivo es Disk-Native.

Aceleración extrema por Hardware: EL caso NVIDIA cuVS

Tamaño de Índice IVF-PQ (100M vectores)



Throughput (Lotes de 10K queries)



Mecánica de la Aceleración

 **Fusión de Operaciones:** Llevar IVF-PQ a la GPU permite fusionar la selección de Top-K directamente con el cálculo de distancias, evitando costosas escrituras en memoria intermedia.


 **Compresión Matemática:** Cuantización agresiva habilitada por el ancho de banda masivo de la GPU.

 **Tablas LUT:** Alojar las Look-Up Tables en la memoria compartida de la GPU satura el ancho de banda, logrando un rendimiento matemáticamente imposible en CPU pura.


Matriz diagnóstica definitiva de indexación vectorial

Algoritmo	Latencia	Consumo RAM	Recall	Caso de Uso Ideal
Flat (Exact kNN)	Lenta ($O(N)$)	Bajo	100%	< 100K Vectores / Precisión absoluta
HNSW	Ultrarrápida (<20ms)	Muy Alto	95-99%	RAG y Chatbots de baja latencia
IVF-PQ	Rápida	Bajo	85-95%	Búsqueda estándar (50M - 500M)
DiskANN / Vamana	Media-Rápida	Mínimo (SSD)	90-95%	Escala Masiva y Petabytes (Billones)
ScaNN	Muy Rápida	Medio	90-95%	Motores de Recomendación (MIPS)

Framework de decisión para arquitectos de sistemas



Disciplina operativa en producción: Más allá del algoritmo



[CAPACITY] Planificación

Estimar la RAM requiere usar factores multiplicadores. Un índice HNSW añade entre 1.5x y 2x de sobrecarga sobre el tamaño del vector base crudo.



[DEGRADATION] Monitoreo

Los índices gráficos manejan mal los borrados continuos (Deletes). Es obligatorio programar reconstrucciones (compaction) para evitar degradación de la latencia.



[DRIFT] Deriva de Modelos

Si el modelo de Embedding cambia upstream (ej. de text-embedding-ada-002 a v3), se DEBE purgar y reconstruir la VDB completa. Los vectores no son retrocompatibles.



[TCO] Estrategia de Hosting

Opte por soluciones Serverless en las etapas de inicio y escalado inicial; evalúe migrar a clústeres Self-Hosted al cruzar la barrera de cientos de millones de vectores para optimizar costos.